Datenanalyse I – Grundbegriffe[1]

Quelle für die folgende ganze Seite: Wikipedia, Statistik[2]

«Statistik „ist die Lehre von Methoden zum Umgang mit quantitativen Informationen“ (Daten). Sie ist eine Möglichkeit, „eine systematische Verbindung zwischen Erfahrung (Empirie) und Theorie herzustellen“. Unter Statistik versteht man die Zusammenfassung bestimmter Methoden zur Analyse empirischer Daten. Ein alter Ausdruck für Statistik war *Sammelforschung*. Die Statistik wird als Hilfswissenschaft von allen empirischen Disziplinen und Naturwissenschaften verwendet, wie zum Beispiel der Medizin (Medizinische Statistik), der Psychologie (Psychometrie), der Politologie, der Soziologie, der Wirtschaftswissenschaft (Ökonometrie), der Biologie (Biometrie), der Chemie (Chemometrie) und der Physik. Die Statistik stellt somit die theoretische Grundlage aller empirischen Forschung dar. Da die Menge an Daten in allen Disziplinen rasant zunimmt, gewinnt auch die Statistik und die aus ihr abgeleitete Analyse dieser Daten an Bedeutung. Andererseits ist die Statistik ein Teilgebiet der reinen Mathematik. Das Ziel der reinen mathematischen Statistik ist das Beweisen allgemeingültiger Aussagen mit den Methoden der reinen Mathematik.

Statistik wird einerseits als eigenständige mathematische Disziplin über das Sammeln, die Analyse, die Interpretation oder Präsentation von Daten, andererseits als Teilgebiet der Mathematik, insbesondere der Stochastik, angesehen.

Die Statistik wird in die folgenden drei Teilbereiche eingeteilt:

- Die deskriptive Statistik (auch Datenanalyse, beschreibende Statistik oder empirische Statistik): Vorliegende Daten werden in geeigneter Weise beschrieben, aufbereitet und zusammengefasst. Mit ihren Methoden verdichtet man quantitative Daten zu Tabellen, graphischen Darstellungen und Kennzahlen. Bei einigen Institutionen ist wie bei der amtlichen Statistik oder beim sozio-oekonomischen Panel (SOEP) die Erstellung solcher Statistiken die Hauptaufgabe.

- Die induktive Statistik (auch mathematische Statistik, schließende Statistik, beurteilende Statistik oder Inferenzstatistik): In der induktiven Statistik leitet man aus den Daten einer Stichprobe Eigenschaften einer Grundgesamtheit ab.
  Die Wahrscheinlichkeitstheorie liefert die Grundlagen für die erforderlichen Schätz- und Testverfahren.

- Die explorative Statistik (auch hypothesen-generierende Statistik, analytische Statistik oder Data-Mining): Dies ist methodisch eine Zwischenform der beiden vorgenannten Teilbereiche, bekommt als Anwendungsform jedoch zunehmend eine eigenständige Bedeutung. Mittels deskriptiver Verfahren und induktiver Testmethoden sucht sie systematisch mögliche Zusammenhänge (oder Unterschiede) zwischen Daten in vorhandenen Datenbeständen und will sie zugleich in ihrer Stärke und Ergebnissicherheit bewerten. Die so gefundenen Ergebnisse lassen sich als Hypothesen verstehen, die erst, nachdem darauf aufbauende, induktive Testverfahren mit entsprechenden (prospektiven) Versuchsplanungen sie bestätigen, als statistisch gesichert gelten können.»

[1] Marthaler, Jakob, Reuter. Mathematik 1. (2015), ausser anders angegeben
[2] https://de.wikipedia.org/wiki/Statistik, Stand 8.8.2020

Grundgesamtheit, Stichprobe

Grundgesamtheit	Die Grundgesamtheit ist die Menge der für die Untersuchung relevanten Personen oder Objekte. [3]Die Grundgesamtheit bezeichnet die Ausgangsgesamtheit (Kollektiv, Population, statistische Masse, Menge aller Elemente), auf die ein Untersuchungsziel in der Statistik gerichtet ist. Die Grundgesamtheit bedarf einer exakten Abgrenzung hinsichtlich folgender Kriterien: o Sachlich (z.B. alle BM-Lernende) o Räumlich (z.B. im Kanton Baselland und Basel-Stadt) o Zeitlich (z.B. zum Zeitpunkt 30.9.2018)
Vollerhebung	Es werden alle relevanten Personen oder Objekte der Grundgesamtheit „befragt“.
Stichprobe, Teilerhebung	Eine Teilmenge der Grundgesamtheit.
Auswahlverfahren für Stichproben	«Bei der Teilerhebung wird aus der Grundgesamtheit lediglich eine kleine, möglichst repräsentative Stichprobe gezogen, die ein realistisches Abbild der Gesamtmasse sein soll. Sie gilt dann als repräsentativ, wenn sie bei der Verteilung der zu erforschenden Merkmale der Grundgesamtheit entspricht. Folgende Arten der Teilerhebung sind zu unterscheiden[4]: • Zufallsauswahl: Das Verfahren ist so angelegt, dass der Zufall darüber entscheidet, ob ein Element in eine Stichprobe aufgenommen wird. Dabei muss jedes Element der Grundgesamtheit eine berechenbare Chance haben, in die Stichprobe aufgenommen zu werden: o Einfache Zufallsauswahl o Geschichtete Stichprobe o Klumpen-Stichprobe • Bewusste Auswahl: Statt des Zufalls entscheiden hier die Forscher nach sachlichen Gesichtspunkten darüber, welche Elemente in die Stichprobe aufgenommen werden.[5]»
Einfache Zufallsauswahl	«Um eine einfache Zufallsauswahl durchführen zu können, müssen alle Elemente der Grundgesamtheit bekannt sein und nummeriert vorliegen. Ist diese Voraussetzung erfüllt, kann die eigentliche Auswahl der Elemente für die Stichprobe nach dem Lotterieverfahren erfolgen, wofür die Grundgesamtheit nach dem Zufallsprinzip durchmischt werden muss. Ist das Lotterieverfahren nicht anwendbar, so kann mit dem Schlussziffern-verfahren (alle Elemente mit der zufällig gewählten Endziffer x werden ausgewählt) oder mit dem Verfahren der systematischen Zufallsauswahl (jedes x-te Element wird ausgewählt, beginnend an einem zufällig bestimmten Startpunkt) eine einfache Zufallsauswahl realisiert werden.[6]»
Umfang, Stichprobenumfang	Die Anzahl der in der Stichprobe untersuchten Personen oder Objekte.
Bias	Wenn die Stichprobe nicht zufällig aus der Grundgesamtheit ausgewählt wird, können systematische Abweichungen auftreten. Solche systematische Abweichungen werden Bias genannt.

[3] Gabler Wirtschaftslexikon. www.wirtschaftslexikon.gabler.de (Stand 5.8.2018)
[4] Nachfolgende Auflistung ist nicht vollständig
[5] Gabler Wirtschaftslexikon. www.wirtschaftslexikon.gabler.de (Stand 5.8.2018)
[6] Marktforschungs-Wiki: https://marktforschung.fandom.com/de/wiki/Einfache_Zufallsauswahl (Stand 8.8.20)

Datensatz, Daten

Datensatz, Daten	Als Datensatz bezeichnet man die Ergebnisse einer Datengewinnung, egal ob die Daten ungeordnet/roh (z.B. Strichliste) oder geordnet (z.B. Häufigkeitstabelle) sind.
Rohdaten, Urliste	Die Daten in der Form wie sie gesammelt wurden, d.h. in der Regel noch ungeordnet.
Untersuchungseinheit	Bei jedem Datensatz werden einzelne Untersuchungseinheiten (z.B. Person A, Person B, etc.) beobachtet, befragt oder vermessen.
Merkmal, Variable	Bei jeder Untersuchungseinheit wir dann ein Merkmal/Variable erhoben (z.B. Haarfarbe, wenn die Untersuchungseinheiten Personen sind).
Ausprägung	Der eine Wert der von der Untersuchungseinheit bezüglich eines Merkmals angenommen wird.
Beobachtung	Alle Ausprägungen einer Untersuchungseinheit.
Variabilität	Entsprechen der Anzahl Variablen, die bei einer Untersuchung eine Rolle spielen, spricht man von – *Univariat*: Datensatz hat genau eine Variable – *Bivariat*: Datensatz hat genau zwei Variablen – *Multivariat*: Datensatz hat mehr als zwei Variablen

Merkmalstypen

Merkmalstypen, Variablentypen, Antwortskalen	Merkmale können anhand gewisser Kriterien in Typen eingeteilt werden. Eine grundlegende Unterscheidung ist folgende: – *Qualitative* Merkmale – *Quantitative* Merkmale
Qualitative Merkmale	Qualitative Merkmale werden auch kategorielle Merkmale genannt. Ihre Ausprägungen können nicht als Zahlenwert erfasst werden, mit denen sinnvoll gerechnet werden kann. Dieser Typ wird weiter unterteilt in: – *Nominal* (z.B. Geschlecht, Augenfarbe, Land) – *Ordinal* (z.B. Fragen mit Antwortmöglichkeiten von „sehr schlecht“ bis „sehr gut“)
Quantitative Merkmale, metrische Merkmale	Quantitative Merkmale werden auch numerische oder metrische Merkmale genannt. Mit ihnen kann gerechnet werden, da ihre Ausprägungen als Zahlenwerte erfasst werden können. Dieser Typ wird weiter unterteilt in: – *Diskret* (z.B. Trefferanzahl beim Basketballspiel) – *Stetig* (z.B. Körpergrösse)

Skalentypen (bei quantitativen Merkmalen)

Intervallskala	Skala ohne absoluten Nullpunkt
Verhältnisskala	Skala mit absolutem Nullpunkt

Methoden der Datengewinnung

Datengewinnung	Um Fragestellungen in Studien zu beantworten, sind Daten notwendig. Um Daten zu gewinnen, werden grundsätzlich folgende zwei Möglichkeiten unterschieden: o Erfassen/Nutzung von im Prinzip vorhandenen Daten: • Befragung, Umfrage • Beobachtungsstudien • Sekundäre Statistik (Datensammlung) o Daten müssen durch zusätzliche Aktionen erst erzeugt werden: • Experiment
Befragung	Befragungen sind ein klassisches Instrument, mit welchem Daten erhoben werden. Im Gegensatz zum Experiment werden keine zusätzlichen Aktionen vorgenommen, um die Daten zu erzeugen. Es gibt verschiedenen Formen: persönlich, telefonisch, online, Papierform.
Beobachtungsstudie	Gleich wie bei einer Befragung werden bei der Beobachtungsstudie grundsätzlich vorhandene Daten erhoben. Die Daten werden jedoch nicht durch Befragen, sondern durch Beobachten oder Messen erfasst.
Sekundäre Studie / Datensammlung	Bei einer sekundärstatistischen Studie werden Daten einer bereits bestehenden Datensammlung verwendet. Die für die Fragestellung relevanten Daten werden aus der Datensammlung herausgefiltert.
Experiment	Bei Experimenten werden die Einflussgrössen kontrolliert und die zugehörigen Werte der Zielgrösse beobachtet.

Fehler der Datengewinnung

Zufällige Fehler	… sind nicht zu verhindern, da z.B. der Messvorgang meist nicht genau gleich wiederholt werden kann, resp. nur beschränkt exakt gemessen werden kann.
Systematische Fehler	… haben ihre Ursache im Messsystem. Die Messwerte sind dann grundsätzlich zu gross, resp. zu klein.
Übertragungsfehler	… können beim Auf – und Abschreiben oder Übertragen der Werte passieren.
Mutwillige Fehler	… liegen vor, wenn einzelne Daten oder gar ganze Datensätze absichtlich gefälscht werden. o Es kommt vor, dass einzelne Messwerte mutwillig angepasst oder gelöscht werden, weil Messfehler vermutet werden. o Ganze Datensätze werden manipuliert, um bestimme Versuchs-ergebnisse überhaupt oder zumindest klarer & besser zu erreichen.